RGB・Depth 情報を用いた UNet による
セマンティックセグメンテーションの実装と工夫

1　課題概要

本課題では、NYUv2 データセットを用いた室内シーンのセマンティックセグメンテーションを行った。入力として RGB 画像および Depth 画像を用い、UNet 構造に基づくモデルを実装した。評価指標には mean Intersection over Union（mIoU）を用いた。本レポートでは、実装過程で直面した問題点と、それに対する工夫について述べる。

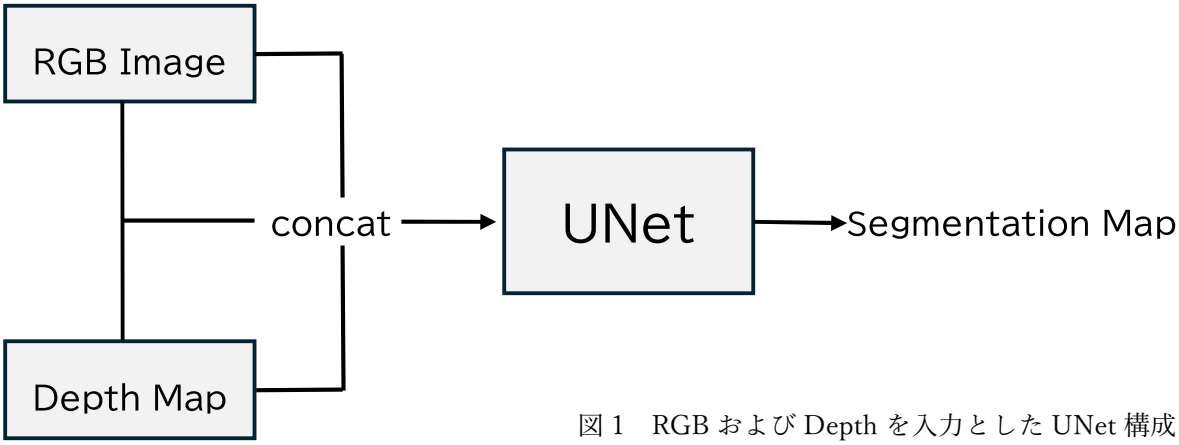

図 1　RGB および Depth を入力とした UNet 構成

実装上の工夫点（要約）
・RGB / Depth / Label の解像度を 256×256 に統一
・教師ラベルは NEAREST 補間を使用
・CrossEntropyLoss と DiceLoss を併用
・validation mIoU に基づく最良モデルの保存
・左右反転による TTA を導入

2　実装上の課題と工夫点

2.1 入力画像と教師ラベルの空間サイズの統一

図 1 に示すように、RGB 画像および Depth 画像をチャネル方向に結合し、UNet に入力した。実装初期段階において、入力画像（RGB・Depth）と教師ラベルの空間サイズが一致していないことにより、学習時にエラーが発生した。セマンティックセグメンテーションでは、CrossEntropyLoss などの損失関数を用いる場合、モデル出力と教師ラベ

ルの空間解像度が完全に一致している必要がある。本実装では、RGB 画像・Depth 画像・教師ラベルのすべてを 256×256 に統一することでこの問題を解決した。特に教師ラベルのリサイズには NEAREST 補間を用い、クラス ID が補間によって破壊されることを防いだ。この処理により、学習が安定して行えるようになった。

2.2 RGB 画像と Depth 画像の統合方法

RGB 画像（3 チャネル）と Depth 画像（1 チャネル）は、チャネル方向に単純に結合し、4 チャネル入力として UNet に入力した。これに伴い、UNet の入力チャネル数を 4 に変更した。Depth 情報を RGB に加算するなどの前処理は行わず、ネットワーク自身に特徴抽出を委ねる構成とした。この方法は実装が単純である一方、Depth が持つ幾何構造情報を自然に利用できると考えられる。

2.3 学習の安定化に関する工夫

損失関数には CrossEntropyLoss と DiceLoss を併用した。CrossEntropyLoss は画素単位の分類精度を重視する一方、DiceLoss はクラス不均衡に対して比較的頑健である。両者を組み合わせることで、学習の安定化と精度向上を図った。また、教師ラベル中の無効領域に対しては ignore_index を設定し、損失計算から除外することで不要な勾配の影響を抑えた。加えて、Mixed Precision（AMP）を用いることで、計算の高速化と数値安定性の向上を図った。

2.4 評価および推論時の工夫

学習中は validation mIoU を用いて性能を監視し、最も性能の良かったモデルのみを保存する方式を採用した。これにより、過学習したエポックのモデルを使用することを避けた。推論時には、左右反転による Test Time Augmentation（TTA）を導入し、通常推論と反転推論の出力を平均することで、予測の安定化と精度向上を図った。単一モデルでありながら、簡易的な工夫で性能改善が得られる点が特徴である。

3　結果と考察

40 エポック学習後、validation mIoU は約 **0.31** に達した。さらに、TTA を用いた提出結果では **mIoU = 0.404** を得た。これらの結果から、入力解像度の統一や損失関数の設計、推論時の工夫が性能向上に寄与したと考えられる。特に、Depth 情報を RGB と併用した点は、室内シーンにおけるセグメンテーション精度向上に有効であった。